

Informe de la Pràctica: Load Balancer

Nerea de la Torre, 1669013 i Adrián Prego, 1672251

Introducció

Aquesta pràctica es centra en garantir disponibilitat contínua, escalabilitat i tolerància a fallades en una aplicació al núvol, mitjançant l'ús de balancejadors de càrrega i grups d'escalat automàtic EC2. A més, s'aplica el patró de desplegament blau/verd per permetre actualitzacions sense interrupcions perceptibles.

Objectiu

L'objectiu d'aquest laboratori és aprendre a dissenyar i implementar arquitectures al núvol que garanteixin alta disponibilitat, tolerància a fallades i escalabilitat. A través de serveis com Amazon EC2, Elastic Load Balancer i Auto Scaling, volem aprendre a gestionar infraestructures robustes i actualitzar aplicacions de manera eficient mitjançant el patró de desplegament blau/verd, minimitzant el temps d'inactivitat.

Fase 1: Alta disponibilitat, tolerància a fallades i monitoratge

Pregunta

Per què són importants les preocupacions transversals com l'alta disponibilitat i la tolerància a errors?

En entorns de producció, l'inactivitat pot significar pèrdues econòmiques considerables. Les arquitectures modernes han d'estar dissenyades per resistir fallades i oferir serveis de manera contínua. L'alta disponibilitat assegura que el servei segueix accessible fins i tot davant d'incidències, mentre que la tolerància a errors permet que el sistema pugui continuar funcionant malgrat fallades parcials.

Pregunta

Quina és la diferència entre escalabilitat i elasticitat?

L'escalabilitat fa referència a la capacitat d'un sistema per augmentar la seva potència (verticalment o horitzontalment) per manejar increments de càrrega. L'elasticitat, en canvi, és la capacitat del sistema per escalar de forma automàtica i dinàmica segons la demanda.

Pregunta

Per què el monitoratge no és només "agradable de tenir" sinó imprescindible?

El monitoratge és essencial per detectar problemes abans que afectin els usuaris. Sense monitoratge, no podem reaccionar proactivament a fallades ni optimitzar l'ús de recursos. Amazon CloudWatch, per exemple, proporciona mètriques en temps real que permeten fer accions automàtiques com escalar instàncies, enviar

alertes o reiniciar serveis, garantint estabilitat i rendiment.

Laboratori 6: Scale and Load Balance Your Architecture

Aquest laboratori d'AWS Academy ens ha permès aprendre a dissenyar una arquitectura altament disponible, tolerant a fallades i escalable automàticament. S'han utilitzat serveis com Elastic Load Balancing (ELB), Auto Scaling i Amazon CloudWatch.

Durant el laboratori hem realitzat les següents tasques:

- Crear una Amazon Machine Image (AMI) a partir d'una instància EC2 ja en funcionament per replicar-la de manera eficient.
Per fer la rèplica de la configuració del nostre servidor, vam crear una **AMI** a partir de la instància **Web Server 1**. Un cop creada, fem servir la AMI per l'Auto Scaling Group.
- Configurar un Application Load Balancer (ALB) per distribuir el trànsit entrant entre múltiples instàncies EC2 ubicades en diverses zones de disponibilitat.
Per distribuir el trànsit entre instàncies EC2, vam crear un **ALB** seguint aquests passos:
 - Crear **Target Group** (LabGroup) vinculat a la VPC del laboratori.
 - Crear l'**Application Load Balancer** (LabELB)
- Per gestionar dinàmicament la capacitat, vam crear una **plantilla de llançament LabConfig** i un **grup d'Auto Scaling** (amb capacitat mínima 2 i màxima 6 instàncies).

Un cop configurat l'Auto Scaling Group:

- Vam llançar 2 instàncies **Lab Instance** automàticament.
- Vam confirmar que estaven **healthy** al **Target Group** (LabGroup).
- Vam accedir a l'aplicació mitjançant el DNS del **Load Balancer** (LabELB), verificant que el trànsit es distribuïa correctament entre instàncies i el balanç de càrrega funcionava com esperat.
- Vam configurar la política d'escalat en CPU mitjana = 60%, que ajusta automàticament el nombre d'instàncies segons la càrrega.

Per garantir una resposta automàtica a la càrrega, vam configurar **alarms de CloudWatch**:

- L'Auto Scaling Group va crear dues alarmes:
 - **AlarmHigh**: activa quan la CPU > 60
 - **AlarmLow**: activa quan la CPU baixa
- Vam simular càrrega amb el botó **Load Test** a l'aplicació.
- CloudWatch va detectar l'increment d'ús de CPU i va activar **AlarmHigh**.
- El grup Auto Scaling va reaccionar llançant **noves instàncies automàticament**.

Un cop fet tot això, lliurem el treball i rebrem el nostre resultat com es mostra en la següent imatge:




Figure 1. Resultats del laboratori de AWS

Gràcies a aquest laboratori hem pogut comprovar com el balanceig de càrrega i l'escalat automàtic permeten mantenir la disponibilitat del servei, optimitzant costos i assegurant una resposta ràpida davant augments puntuals de trànsit.

Fase 2: Disseny d'arquitectura desplegament blau/verd

Objectiu de la fase

Quan volem desplegar una nova versió d'una aplicació, aquesta no està disponible quan la recarreguem i la reiniciem. L'objectiu d'aquesta fase és dissenyar una arquitectura a AWS que implementi el patró de desplegament Blue/Green, per migrar el nostre servidor web de "httpd" a "nginx" i podrem redirigir qualsevol nou trànsit entrant a la nova versió del nostre servidor web. Des del punt de vista de l'usuari, el desplegament de la nova versió es produeix sense temps d'inactivitat visible. Aquesta arquitectura ha de permetre fer actualitzacions sense temps d'inactivitat, assegurant alhora alta disponibilitat, escalabilitat i tolerància a fallades.

Descripció de l'arquitectura proposada

La solució proposada consisteix en crear dos entorns independents però idèntics:

- **Entorn Blau:** utilitza servidors EC2 amb Apache (httpd) per representar la versió actual de l'aplicació.
- **Entorn Verd:** utilitza servidors EC2 amb Nginx per representar la nova versió de l'aplicació.

El disseny de l'arquitectura (Figure 2) a AWS es basa en una VPC amb 4 subxarxes, 2 públiques i 2 privades, en dues zones de disponibilitat. Els dos entorns (Blue/Green) i les seves instàncies EC2 s'allotgen a les subxarxes públiques, ja que imiten el servidor web i cal accés obert a tots els usuaris. Es configuren els recursos següents (hem aprofitat els recursos del Lab 6, que ja creava la VPC, etc.):

- **VPC:** Creació d'una VPC per allotjar totes les instàncies i recursos de xarxa.
- **Subxarxes:**

- **Públiques:** Una subxarxa pública a cada zona de disponibilitat (utilitzem dues) per allotjar instàncies EC2 accessibles des d'Internet, o sigui els nostre servidors webs.
- **Privades:** Una subxarxa privada a cada zona de disponibilitat per allotjar instàncies que no estan accessibles directament des d'Internet, que de moment seràn buides, però es podrien utilitzar per guardar una base de dades RDS en el cas que fos necessari.

- **Gateway d'Internet:** Proporciona accés a Internet per a les instàncies de la subxarxa pública.
- **NAT Gateway:** Per permetre que les instàncies de les subxarxes privades tinguin accés a Internet per actualitzacions i altres serveis sense exposar-les directament.
- **Application Load Balancer (ALB):** S'encarrega de distribuir el trànsit d'entrada entre els dos entorns, segons una estratègia de trànsit definida.
- **Grups d'Auto Scaling:** Dos, un per a l'entorn blau (Apache) i un per a l'entorn verd (Nginx).
- **Target Groups:** Per separar les instàncies de l'entorn blau i verd.
- **Instàncies EC2:** Els servidors que reben el trànsit. Una instància EC2 desplegada en cada subxarxa pública. Cada target grup s'afegeix a un Auto Scaling Group, amb mínim 1 instància per AZ.

També incloem a l'arquitectura (ja creat automàticament per el Lab 6)...:

- **Grups de seguretat:** Un grup de seguretat per a les instàncies EC2 per permetre l'accés HTTP a les instàncies de les subxarxes públiques.
- **NACL's:** Per defecte se li assigna a cada subxarxa la NACL per defecte de la VPC. Són firewalls a nivell de subxarxa. Serveixen per controlar el tràfic d'entrada i sortida de cada subxarxa a través de regles basades en adreces IP i ports.
- **Taules de rutes:** Dues taules de rutes, una per la subxarxa pública i una altra per la subxarxa privada.




Figure 2. Disseny arquitectura Blue/Green

Justificació de les decisions preses

- **Application Load Balancer (ALB):** triat per la seva capacitat de fer *routing* per camins i percentatges, ideal per a desplegaments progressius, com en el nostre cas de actualització del servidor web.
- **Auto Scaling Groups:** permeten escalar automàticament cada entorn segons la càrrega, garantint elasticitat.
- **Multi-AZ:** es distribueixen instàncies a dues zones de disponibilitat per garantir alta disponibilitat i tolerància a fallades.
- **Subxarxes públiques:** les instàncies EC2 amb el servidor web estan exposades directament a Internet, garantint l'accés directe dels usuaris.

Llista de pros i contres del disseny

Pros

- Alta disponibilitat i tolerància a fallades.
- Desplegament sense interrupcions visibles per l'usuari.
- Possibilitat de revertir fàcilment en cas d'error en el desplegament.
- Escalabilitat automàtica segons la càrrega.

Contres

- Increment del cost per mantenir dos entorns en paral·lel.
- Major complexitat de gestió i configuració.
- Necessitat de control precís del trànsit per evitar inconsistències.

Fase 3: Implementació de l'arquitectura proposada a AWS

Objectiu de la fase

Aquesta fase consisteix a implementar al núvol AWS l'arquitectura dissenyada a la Fase 2. Cal desplegar tots els components descrits i demostrar, mitjançant captures de pantalla i breus explicacions, que el sistema funciona correctament i suporta el flux de trànsit blau/verd, inclòs un procés de reversió.

Desplegament dels recursos

Creació de la VPC i subxarxes

Mitjançant els recursos inclosos al laboratori 6 del mòdul 10, aprofitem la configuració de la VPC i les quatre subxarxes (dues públiques i dues privades) distribuïdes en dues zones de disponibilitat (AZs). A més de les configuracions:

- Internet Gateway associat a la VPC.
- Taules de rutes per a subxarxes públiques i privades.
- NAT Gateway en subxarxes públiques per donar accés a Internet a les subxarxes privades.
- Web Security Group (ens assegurem que estigui obert el port 80 i permeti ingressos des d'Internet).

Creació dels Target Groups blue i green

1. Anem a AWS Console → EC2 → Target Groups → Create target group
2. **Target type:** Instances

3. **Name:** Blue-TG
4. **Protocol:** HTTP, port 80
5. **Health check:** HTTP sobre /

Repetim els mateixos passos per **Green-TG**.

Llançem les Launch Templates:

1. Plantilla Blue

- Nom: LT-Blue
- AMI ID: WebServerAMI
- Instance type: t2.micro
- Security Group: Web Security Group
- Utilitzem la plantilla per l'entorn Blue de l'enunciat en User data:

```
1 #!/bin/bash
2 yum install -y httpd
3 cat <<HEREDOC > /var/www/html/index.html
4 <html><body bgcolor="#5DBCD2">
5 <h1>Lab 3 - Blue/Green Deployment Use Case
6 </h1>
7 <h2>This is our Blue Environment</h2>
8 </body></html>
9 HEREDOC
10 service httpd enable
11 service httpd start
```

2. Plantilla Green

- Nom: LT-Green
- Utilitzem la plantilla per l'entorn Green de l'enunciat en User data:

```
1 #!/bin/bash
2 amazon-linux-extras install nginx1 -y
3 mv /usr/share/nginx/html/index.html /usr/
4 share/nginx/html/index.html.orig
5 cat <<HEREDOC > /usr/share/nginx/html/
6 index.html
7 <html><body bgcolor="#98FB98">
8 <h1>Lab 3 - Blue/Green Deployment Use Case
9 </h1>
10 <h2>This is our Green Environment</h2>
11 </body></html>
12 HEREDOC
13 service nginx enable
14 service nginx start
```

Configuració l'Application Load Balancer (ALB)

- Nom: ALB-BlueGreen
- Listener: HTTP port 80
- Subnets: AZs amb subnets públiques

Creació dels Auto Scaling Groups

1. ASG Blue

- Nom: ASG-Blue
- Launch Template: LT-Blue
- Subnets: les dues subnets públiques
- Load Balancing: escollim el nostre ALB-BlueGreen → marquem només el target group **Blue-TG**
- Desired capacity: mínim 2, màxim 6
- Scaling policy: Target tracking – CPU 60%

2. ASG Green

Mateix procés però:

- Nom: ASG-Green
- Launch Template: LT-Green
- Load Balancing: ara marquem el **Green-TG**

Configurem pesos del trànsit de l'ALB:

Per configurar la distribució de trànsit dividida, fem:

1. Anem al nostre ALB-BlueGreen, **Listeners** → **HTTP:80** → **View/edit rules**
2. Editem la regla per defecte
3. Canviem acció a: **Forward to multiple target groups**
4. Assignem:
 - Blue-TG: Weight 80
 - Green-TG: Weight 20

Verificació del Funcionament de l'Equilibri de Càrrega

1. Ens dirigim a **Instàncies**.
2. Veiem quatre instàncies noves. Aquestes han estat llançades mitjançant *Auto Scaling*, 2 per l'entorn Blue i 2 per l'entorn Green.
3. Per confirmar que les noves instàncies han superat la comprovació de salut (*Health Check*), ens dirigim a **Target Groups** i seleccionem Blue-TG i Green-TG.
4. Triem la pestanya **Targets** y 4 instàncies haurien d'aparèixer al grup d'objectiu amb l'estat (**healthy**). Això ens indica que una instància ha superat la comprovació de salut del Load Balancer. El que significa que el Load Balancer enviarà tràfic a la instància.

Accedim al Servidor Web

- Ens dirigim a **Load Balancers** i seleccionem el nostre equilibrador de càrrega ALB-BlueGreen.
- Al panell de detalls, copiem el nom DNS de l'equilibrador de càrrega, amb el format: `http://ALB-BlueGreen-1413942537.us-east-1.elb.amazonaws.com`
- Obrim una nova pestanya del navegador web i enganxem el nom DNS.

Proves i divisió de trànsit

Estratègia de trànsit

Hem iniciat la càrrega de trànsit amb 80% cap el Blue i 20% cap el Green. Provem el DNS de l'ALB i observem si rebem els entorns blau i verd:




Figure 3. Servidor web Blue




Figure 4. Servidor web Green

Progressivament canviem a 50/50, després 20/80 i finalment 0/100. Per cada pas, hem pres captures de pantalla des del panell de l'ALB mostrant la configuració i s'ha verificat l'accés web a l'URL pública de l'ALB per comprovar el color de fons corresponent. A continuació mostrem els canvis en les captures:

1. 80% blau / 20% verd:




Figure 5. Configuració 80/20

2. 50% blau / 50% verd:

Forward to target group

- Blue-TG: 1 (50%)
- Green-TG: 1 (50%)
- Target group stickiness: Off

Figure 6. Configuració 50/50

3. 20% blau / 80% verd:

Forward to target group

- Green-TG: 4 (80%)
- Blue-TG: 1 (20%)
- Target group stickiness: Off

Figure 7. Configuració 20/80

4. 0% blau / 100% verd:

Forward to target group

- Green-TG: 1 (100%)
- Blue-TG: 0 (0%)
- Target group stickiness: Off

Figure 8. Configuració 0/100

Reversió

Per simular una fallada al verd, hem modificat manualment el User data perquè falli el servei i modificar el *health check* per considerar les instàncies Nginx com a "unhealthy". Com que el Load Balancer d'AWS no fa automàticament la redirecció del trànsit entre els entorns si es detecta un error en un d'ells, hem modificat manualment la configuració del Listener per posar 100% del trànsit cap a Blue. Si es volgués fer aquest rollback de forma automàtica, caldria configurar alarmes a CloudWatch i vincular-les amb una funció Lambda mitjançant EventBridge per canviar els pesos quan es detecta un problema.

Forward to target group

- Blue-TG: 1 (100%)
- Green-TG: 0 (0%)
- Target group stickiness: Off

Figure 9. Canvi a 100% blue

D'aquesta forma, afirmem que en el cas que el nou desplegament no funcioni, tornem als nostres usuaris a la versió anterior sense que ningú se'n adoni.

Temes fora de l'abast

Si es disposés de més temps, es podrien considerar els següents punts addicionals:

- Validació de l'estat de salut de les aplicacions mitjançant scripts personalitzats.
- Monitoratge avançat amb Amazon CloudWatch i alarmes per detectar fallades.

Problemes i Solucions

Durant el desplegament de l'entorn **verd**, vam detectar que la pàgina no mostrava el contingut esperat ("This is our Green Environment"), sinó la pàgina per defecte de l'Academy ("Welcome to Academy Cloud Foundations"). A continuació, exposem en detall els problemes trobats i les solucions aplicades, pas a pas:

- **La instància no tenia IP pública assignada:** després de crear l'entorn verd, les instàncies llançades automàticament pel Launch Template no tenien IP pública. Per solucionar-ho, accedim a la consola d'EC2, i des de **Actions > Networking > Manage IP Addresses** vam assignar manualment una IP pública a una de les instàncies verdes.
- **NGINX no estava instal·lat correctament:** tot i haver previst la seva instal·lació, inicialment no funcionava perquè vam utilitzar una AMI Amazon Linux 2023, la qual no permetia instal·lar fàcilment NGINX.

Per solucionar el problema, vam accedir a una de les instàncies verdes mitjançant l'opció **Connect > SSH** des de la consola d'EC2. Un cop dins, procedim a instal·lar NGINX manualment amb:

```
1 sudo dnf install nginx -y
```

- **Conflicte de port 80:** en intentar iniciar el servei de NGINX amb:

```
1 sudo systemctl start nginx
```

es va produir un error perquè el port 80 ja estava ocupat pel servei Apache (**httpd**), que s'executava per defecte. Ho vam confirmar amb:

```
1 sudo lsof -i :80
```

- Per solucionar-ho, vam aturar i desactivar el servei Apache amb els següents comandaments:

```
1 sudo systemctl stop httpd
2 sudo systemctl disable httpd
```

Després, vam tornar a iniciar el servei NGINX.

- **La pàgina mostrava el missatge per defecte de NGINX:** encara que NGINX funcionava, es visualitzava la pàgina "Welcome to nginx!" perquè el fitxer `/usr/share/nginx/html/index.html` no contenia el contingut esperat. Ho vam reemplaçar amb el següent:

```
1 echo '<html>
2 <head>
3 </head>
4 <body bgcolor="#98FB98">
5 <h1>Lab 3 - Blue/Green Deployment Use Case
6 </h1>
7 <h2>This is our Green Environment</h2>
8 </body>
9 </html>' | sudo tee /usr/share/nginx/html/
10 index.html
```

- **Seguia la pàgina antiga:** després de modificar el fitxer, la pàgina seguia mostrant la versió anterior. Vam solucionar-ho forçant una recàrrega sense memòria cau amb les tecles **Ctrl + F5**.

Gràcies a aquests passos, vam aconseguir finalment que l'entorn verd mostrés correctament la pàgina verda.

Conclusió i beneficis del desplegament

Aquest disseny d'arquitectura permet una actualització segura i controlada de l'aplicació web, minimitzant els riscos i impactes dels desplegaments. La implementació del patró Blue/Green afavoreix la continuïtat del servei i la rapidesa en les actualitzacions. Aquest desplegament ofereix diversos avantatges:

- **Zero downtime:** els usuaris no perceben interrupcions durant els desplegaments.
- **Reversió ràpida:** possibilitat de tornar a la versió anterior en cas de problemes, minimitzant l'impacte.
- **Escalabilitat i elasticitat:** els entorns utilitzen Auto Scaling, adaptant-se a la càrrega en temps real.